

しおん研-ゼロつくゼミ

第6回

今日やること

- ▶ 様々な最適化手法
- ▶ パラメータの初期値の設定

学習の目的：損失が最小になるようなパラメータを決定する！（最適化）

そのためには、気をつけるべきことが沢山・・・

- ▶ モデルの表現力
- ▶ 汎化性能
- ▶ 局所最適解の問題
- ▶ 勾配消失
- ▶ 最適なパラメータへ辿り着くまでの速さ etc...

それらを改善するために、様々な最適化手法が考えられている。

色々な最適化手法

- ▶ SGD（確率的勾配降下法）
- ▶ Momentum
- ▶ AdaGrad
- ▶ RMSprop
- ▶ Adam

今回は、これらを順に実装していく。

The background is a vibrant collage of geometric shapes and patterns in various shades of green and yellow. It includes a grid of dots in the top left, a large circle with a dot pattern, a 3D rectangular prism with diagonal lines, a solid yellow square, a circle with diagonal lines, a 3D L-shaped block, a target-like concentric circle pattern, a 5x5 grid of dots, a 3D cube, and a wavy line pattern. The overall style is modern and abstract.

最適化手法を
クラスで取り
出してみる

Momentum


$$w_{t+1} = w_t + v_t$$
$$v_t = \mu v_{t-1} - \eta \frac{\partial C(w)}{\partial w}$$

目的：パラメータを調整する勾配を「勾配の移動平均」とすることで、最適解への到達を速くする

(出典：<https://qiita.com/supersaiakujin/items/d9795c34cecd1438b711>)

Momentum

式を書き換えると・・・



$$\nu_t = \beta \nu_{t-1} + (1 - \beta)G$$

$$w_t = w_{t-1} - \alpha \nu_t$$



勾配の移動平均

：一定の力を受けた物体の速度

出典：

<https://qiita.com/omiita/items/1735c1d048fe5f611f80>

AdaGrad

$$G_t = G_{t-1} + dw^2$$

$$w_{new} = w_{old} - \frac{\alpha}{\sqrt{G_t + \epsilon}} \odot dw$$

目的：勾配の各成分が大きいとき、それに応じて各成分の学習率の値を小さくする
→「行きすぎることを防いで、最適解までの到達を速くする！

問題点：学習が進むと学習率が0に近づいてしまう→勾配消失の可能性

RMSprop

$$\mathbf{h}_{i+1} = \rho \mathbf{h}_i + (1 - \rho)(\nabla f)^2 \quad (1)$$

$$\mathbf{x}_{i+1} = \mathbf{x}_i - \eta \frac{1}{\sqrt{\mathbf{h}_{i+1}}}(\nabla f) \quad (2)$$

目的： ρ ($0 < \rho < 1$) をとることで、AdaGradで発生していた勾配消失の可能性を排除

(出典 ; <https://watlab-blog.com/2020/03/09/rmsprop/>)

Adam

$$\nu_t = \beta_1 \nu_{t-1} + (1 - \beta_1)G$$

$$s_t = \beta_2 s_{t-1} + (1 - \beta_2)G^2$$

$$w_t = w_{t-1} - \alpha \frac{\nu_t}{\sqrt{s_t + \epsilon}}$$

Momentum と RMSprop の合体版

- これまでの勾配の影響を考慮
- 勾配の大きさによって学習幅を調整



最適化手法 の実装

初期値はどうやって決める？

- ▶ 初期値によって、学習の結果が大きく変化する！

- ▶ （例えば・・・）

パラメータ行列の各要素が、ある一定の値の周辺に偏っている：表現力の低下
重みが大きい：過学習


（ちなみに）「重みの初期値を全部0にすると、パラメータが重複した値を持つようになる」は、割と嘘です。ただし、学習がとても遅くなることがわかっています。

とにかく、適切な初期値を決めることがとても大切。


（出典：<https://n3104.hatenablog.com/entry/2017/07/16/154042>）

各層のアクティベーション分布

- ▶ 学習がうまく機能しているかどうかを調べるのに、各層のアクティベーション分布を調べることが多い。
- ▶ アクティベーション：活性化関数の後の出力データ
- ▶ 下は5層のニューラルネットワークに、100個のパラメータを持つデータを1000個突っ込んだ時のアクティベーション分布



重みの初期値：平均0,標準偏差1の正規分布



初期値：標準偏差0.01の正規分布

アクティベー
ション分布を実
装で確認する回



各層のアクティベーション分布

- ▶ 標準偏差1 → アクティベーション分布が0と1に偏る
→ (例えばシグモイド関数なら) 勾配が0になってしまう・・・ (勾配消失)
- ▶ 標準偏差0.01 → アクティベーション分布の偏りが大きすぎる
→ パラメータを増やす意味がなくなってしまう・・・ (表現力の低下)

(復習) シグモイド関数の逆伝播

sigmoid関数 :

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

sigmoid関数の微分 :

$$\text{sigmoid}'(x) = \frac{1}{1 + e^{-x}} * (1 - \frac{1}{1 + e^{-x}})$$

じゃあ、最適な初期値って何？

Sigmoid関数の初期値：Xavierの初期値

▶ 各層における入力時のノード数を n とすると、

▶ 重みを、

平均0、標準偏差 $1/\sqrt{n}$ の正規分布 で初期化する！

・ 前層のパラメータの数が多いほど、対象ノードの初期値として設定する重みのスケールは小さくなる。

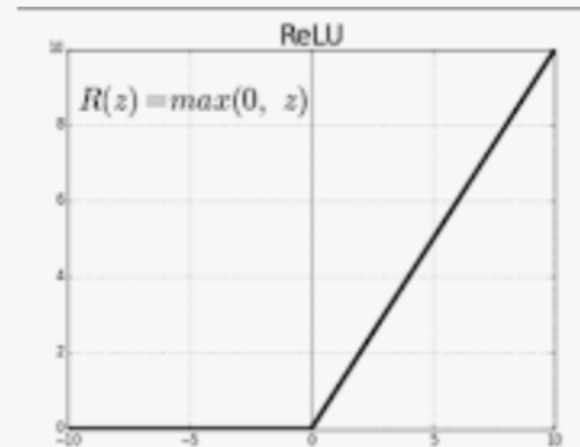

(イメージ：特徴量を増やせば増やすほど、その中の一つの特徴量に影響される度合いを少なくする)

初期値の設定とアクティベーション 分布の変化の実装



Relu関数の初期値：Heの初期値

- ▶ 各層における入力時のノード数を n とすると、
- ▶ 重みを、
平均0、標準偏差 $\sqrt{2/n}$ の正規分布 で初期化する！
- ▶ Sigmoidより広がりを持たせた初期値の設定
(アクティベーションがより均一になりやすいため)



Mnistでの実装

```
mirror_mod = modifier_ob.  
set mirror object to mirror  
mirror_mod.mirror_object =  
operation == "MIRROR_X":  
mirror_mod.use_x = True  
mirror_mod.use_y = False  
mirror_mod.use_z = False  
operation == "MIRROR_Y":  
mirror_mod.use_x = False  
mirror_mod.use_y = True  
mirror_mod.use_z = False  
operation == "MIRROR_Z":  
mirror_mod.use_x = False  
mirror_mod.use_y = False  
mirror_mod.use_z = True
```

```
selection at the end -add  
mirror_ob.select= 1  
modifier_ob.select=1  
context.scene.objects.active  
("Selected" + str(modifier_ob.  
mirror_ob.select = 0  
= bpy.context.selected_object  
data.objects[one.name].select  
print("please select exactly
```

--- OPERATOR CLASSES ---

```
types.Operator):  
on X mirror to the selected  
object.mirror_mirror_x"  
mirror X"
```

```
context):  
context.active_object is not
```